

דוח ניתוח נתונים: פרויקט העשרת מידע על סרטים (IMDb & Wikipedia)

קבוצה 18: אמיתי מרמור

1. החלטות מרכזיות בבניית סט הנתונים

במהלך הפרויקט התקבלו מספר החלטות כדי להבטיח את איכות הנתונים ויציבות הקוד:

- **מודל איסוף מדורג: (Fallback Mechanism)** הוחלט להשתמש ב IMDb-כמקור בסיס, ולבצע "סבבי הצלה" מוויקיפדיה כדי למלא חוסרים בעמודות עלילה, תקציב והכנסות.
- **מעבר ל-API:** לאחר שהתברר שסריקת HTML (Scraping) היא שבירה מדי, הוחלט לעבור לעבודה עם ה-API הרשמי של ויקיפדיה וחילוץ נתונים מתוך קוד המקור באמצעות Regexp, מה ששיפר משמעותית את אחוז הדיוק.
- **ניקוי חריגים:** הוחלט לסנן סרטים בעלי מספר נמוך של הצבעות כיוון שהנתונים שלהם בוויקיפדיה מאוד דלים אם קיימים בכלל ונרשמו 5,000 סרטים לאחר כל הסינונים.

2. תיאור שדות הנתונים

הטבלה הסופית (df_final) כוללת את השדות הבאים:

שם השדה	טיפוס נתון	מקור הנתון	תיאור
tconst	String	IMDb	מזהה ייחודי של הסרט.
primaryTitle	String	IMDb	שם הסרט המקורי.
startYear	Integer	IMDb	שנת יציאת הסרט לקולנוע.
genres	String*	IMDb	ז'אנרים של הסרט
lead_actors_ids	List if strings	IMDb	רשימת חמשת השחקנים המובילים בסרט
runtimeMinutes	Integer	Wikipedia	משך הזמן בדקות
averageRating	Float	Wikipedia	דירוג ממוצע לפי IMDb
Language	String	Wikipedia	שפת הסרט
Country	String	Wikipedia	המדינה בה נוצר הסרט
numVotes	Integer	IMDb	מספר מדרגים
budget	Float	Wikipedia	תקציב הפקה במיליוני דולרים
BoxOffice	Float	Wikipedia	הכנסות גלובליות במיליוני דולרים
plot	String	Wikipedia	תקציר הסרט

* נאמר בעבודה לעשות רשימה של מחרוזות אך כתוב גם לעשות בדיוק לפי מה שנמצא בטבלה המקורית. בטבלה המקורית יש שם מחרוזת ולכן בחרתי להשאיר את הטיפוס בדיוק כמו שהיה, ללא שינוי.

3. כמות נתונים וערכים חסרים

מספר סרטים סופי בסט הנתונים: 5,000 סרטים.

להלן פירוט הערכים החסרים (לאחר ביצוע כל סבבי ההשלמה והניקוי):

עמודה	מספר ערכים חסרים	אחוז חסר
עלילה (Plot)	1,525	30.5%
תקציב (Budget)	3,535	70.7%
שפה (Language)	1,200	24.0%
מדינה (Country)	1,306	26.1%
הכנסות (BoxOffice)	3,289	65.8%

הערה: אחוז החוסר בנתונים הכספיים (תקציב והכנסות) גבוה משאר העמודות. דבר זה נובע מכך שוויקיפדיה לרוב אינה מתעדת נתונים אלו עבור סרטים שאינם שוברי קופות הוליוודיים או עבור סרטים ישנים מאוד/עצמאיים.

4. סיכום ומסקנות

פרויקט זה עוסק בתהליך של איסוף וארגון נתונים ממקורות שונים. המטרה המרכזית הייתה לקחת את המידע הבסיסי של IMDb ולהעשיר אותו בפרטים חסרים מתוך ויקיפדיה, כמו תקציב, הכנסות ועלילה.

במהלך העבודה היו מספר אתגרים:

- שילוב מקורות בין קבצי נתונים ענקיים לבין חיפוש אוטומטי באינטרנט.
 - דינמיות וגמישות המערכת: המסקנה היא שאיסוף נתונים מהרשת מחייב קוד גמיש. נבנתה מערכת שלא נשברת כשהפורמט משתנה ובכך מבטיחה אחוז הצלחה גבוה יותר בחילוץ הנתונים.
 - ניקוי נתונים מטקסט חופשי ומסובך למספרים ונתונים מסודרים שקל לנתח.
- התוצאה הסופית היא מאגר נתונים מלא ומדויק יותר מהמקור, שמאפשר להפיק תובנות על עולם הקולנוע בצורה פשוטה ונוחה.